


2장. 기계학습과 수학

강원대학교 빅데이터메디컬융합학과
: 헬스케어 분야에서의 딥러닝

한빛아카데미
HANBIT ACADEMY INC.



MACHINE 기계 학습
LEARNING
오일석 지음

본 강의자료는 한빛아카데미에서 제공하는 강의자료를 바탕으로 작성되었음



PREVIEW

■ 기계 학습에서 수학의 역할

- **수학**은 목적함수를 정의하고, 목적함수가 최저가 되는 점을 찾아주는 최적화 이론 제공
- 최적화 이론에 규제, 모멘텀, 학습률, 멈춤조건과 같은 제어를 추가하여 **알고리즘** 구축
- **사람**은 알고리즘을 설계하고 데이터를 수집함

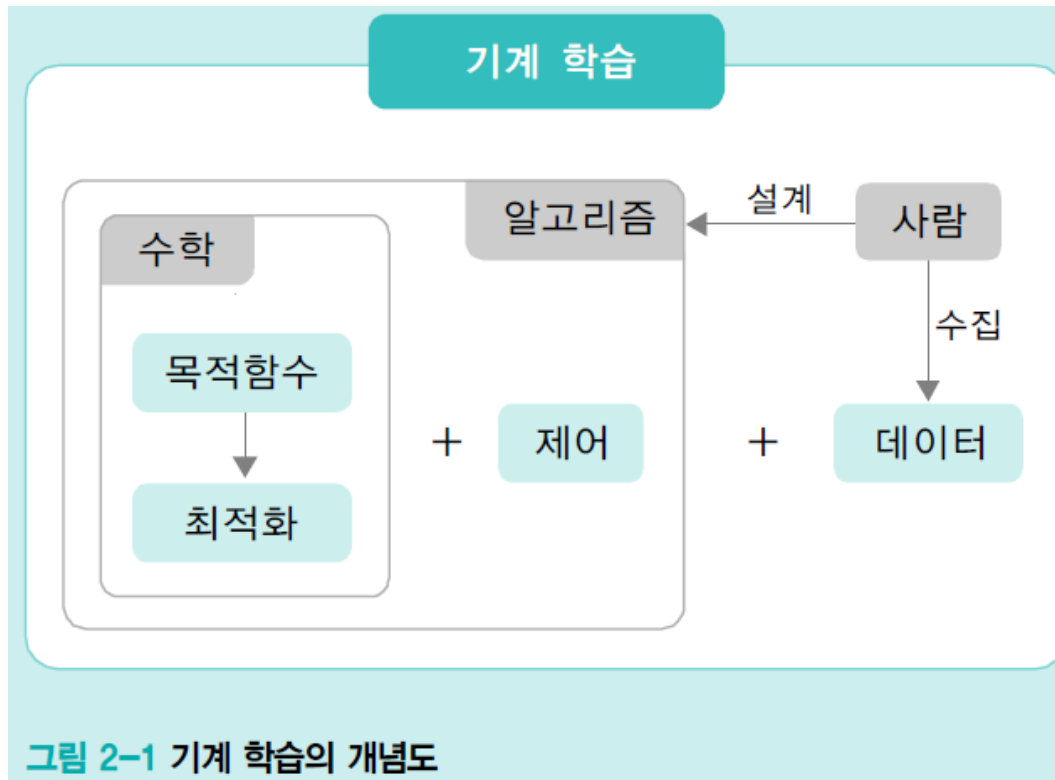


그림 2-1 기계 학습의 개념도



각 절에서 다루는 내용

- 2.1절: 선형대수를 다룬다.
- 2.2절: 확률과 통계를 다룬다.
- 2.3절: 최적화 이론을 다룬다.

- 선형대수: 이 분야의 개념을 이용하면 학습 모델의 매개변수집합, 데이터, 선형연산의 결합 등을 행렬 또는 텐서로 간결하게 표현할 수 있다. 데이터를 분석하여 유용한 정보를 알아내거나 특징 공간을 변환하는 등의 과업을 수행하는 데 핵심 역할을 한다.
- 확률과 통계: 데이터에 포함된 불확실성을 표현하고 처리하는 데 활용한다. 베이즈 이론과 최대 우도 기법을 이용하여 확률 추론을 수행한다.
- 최적화: 목적함수를 최소화하는 최적해를 찾는 데 활용하며, 주로 미분을 활용한 방법을 사용한다. 수학자들이 개발한 최적화 방법을 기계 학습이라는 도메인에 어떻게 효율적으로 적용할지가 주요 관심사이다.



2.1 선형대수

- 2.1.1 벡터와 행렬
- 2.1.2 놈과 유사도
- 2.1.3 퍼셉트론의 해석
- 2.1.4 선형결합과 벡터공간
- 2.1.5 역행렬
- 2.1.6 행렬 분해



2.1.1 벡터와 행렬

■ 벡터

- 샘플을 특징 벡터로 feature vector 표현
- 예) Iris 데이터에서 꽃받침의 길이, 꽃받침의 너비, 꽃잎의 길이, 꽃잎의 너비라는 4개의 특징이 각각 5.1, 3.5, 1.4, 0.2인 샘플

$$\mathbf{x} = \begin{pmatrix} x_1 \\ x_2 \\ x_3 \\ x_4 \end{pmatrix} = \begin{pmatrix} 5.1 \\ 3.5 \\ 1.4 \\ 0.2 \end{pmatrix}$$

- 여러 개의 특징 벡터를 첨자로 구분

$$\mathbf{x}_1 = \begin{pmatrix} 5.1 \\ 3.5 \\ 1.4 \\ 0.2 \end{pmatrix}, \mathbf{x}_2 = \begin{pmatrix} 4.9 \\ 3.0 \\ 1.4 \\ 0.2 \end{pmatrix}, \mathbf{x}_3 = \begin{pmatrix} 4.7 \\ 3.2 \\ 1.3 \\ 0.2 \end{pmatrix}, \dots, \mathbf{x}_{150} = \begin{pmatrix} 5.9 \\ 3.0 \\ 5.1 \\ 1.8 \end{pmatrix}$$



2.1.1 벡터와 행렬

■ 행렬

- 여러 개의 벡터를 담음
- 훈련집합을 담은 행렬을 설계행렬이라 부름
- 예) Iris 데이터에 있는 150개의 샘플을 설계 행렬 \mathbf{X} 로 표현

$$\mathbf{X} = \begin{pmatrix} 5.1 & 3.5 & 1.4 & 0.2 \\ 4.9 & 3.0 & 1.4 & 0.2 \\ 4.7 & 3.2 & 1.3 & 0.2 \\ 4.6 & 3.1 & 1.5 & 0.2 \\ \vdots & \vdots & \vdots & \vdots \\ 6.2 & 3.4 & 5.4 & 2.3 \\ 5.9 & 3.0 & 5.1 & 1.8 \end{pmatrix} = \begin{pmatrix} x_{1,1} & x_{1,2} & x_{1,3} & x_{1,4} \\ x_{2,1} & x_{2,2} & x_{2,3} & x_{2,4} \\ x_{3,1} & x_{3,2} & x_{3,3} & x_{3,4} \\ x_{4,1} & x_{4,2} & x_{4,3} & x_{4,4} \\ \vdots & \vdots & \vdots & \vdots \\ x_{149,1} & x_{149,2} & x_{149,3} & x_{149,4} \\ x_{150,1} & x_{150,2} & x_{150,3} & x_{150,4} \end{pmatrix}$$

← 행 row

↑
열 column



2.1.1 벡터와 행렬

■ 행렬 \mathbf{A} 의 전치행렬 \mathbf{A}^T

$$\mathbf{A} = \begin{pmatrix} a_{11} & a_{12} & \cdots & a_{1m} \\ a_{21} & a_{22} & \cdots & a_{2m} \\ \vdots & \vdots & \ddots & \vdots \\ a_{n1} & a_{n2} & \cdots & a_{nm} \end{pmatrix}, \quad \mathbf{A}^T = \begin{pmatrix} a_{11} & a_{21} & \cdots & a_{n1} \\ a_{12} & a_{22} & \cdots & a_{n2} \\ \vdots & \vdots & \ddots & \vdots \\ a_{1m} & a_{2m} & \cdots & a_{nm} \end{pmatrix}$$

예를 들어, $\mathbf{A} = \begin{pmatrix} 3 & 4 & 1 \\ 0 & 5 & 2 \end{pmatrix}$ 라면 $\mathbf{A}^T = \begin{pmatrix} 3 & 0 \\ 4 & 5 \\ 1 & 2 \end{pmatrix}$

- Iris의 설계 행렬을 전치행렬 표기에 따라 표현하면,

$$\mathbf{X} = \begin{pmatrix} \mathbf{x}_1^T \\ \mathbf{x}_2^T \\ \vdots \\ \mathbf{x}_{150}^T \end{pmatrix} \quad \leftarrow \quad \mathbf{x} = \begin{pmatrix} x_1 \\ x_2 \\ x_3 \\ x_4 \end{pmatrix} = \begin{pmatrix} 5.1 \\ 3.5 \\ 1.4 \\ 0.2 \end{pmatrix}$$



2.1.1 벡터와 행렬

■ 행렬을 이용하면 수학을 간결하게 표현할 수 있음

- 예) 다항식의 행렬 표현

$$f(\mathbf{x}) = f(x_1, x_2, x_3)$$

$$= 2x_1x_1 - 4x_1x_2 + 3x_1x_3 + x_2x_1 + 2x_2x_2 + 6x_2x_3 - 2x_3x_1 + 3x_3x_2 + 2x_3x_3 + 2x_1 + 3x_2 - 4x_3 + 5$$

$$= (x_1 \ x_2 \ x_3) \begin{pmatrix} 2 & -4 & 3 \\ 1 & 2 & 6 \\ -2 & 3 & 2 \end{pmatrix} \begin{pmatrix} x_1 \\ x_2 \\ x_3 \end{pmatrix} + (2 \ 3 \ -4) \begin{pmatrix} x_1 \\ x_2 \\ x_3 \end{pmatrix} + 5$$

$$= \mathbf{x}^T \mathbf{A} \mathbf{x} + \mathbf{b}^T \mathbf{x} + c$$

■ 특수한 행렬들

$$\text{정사각행렬} \begin{pmatrix} 2 & 0 & 1 \\ 1 & 21 & 5 \\ 4 & 5 & 12 \end{pmatrix}, \quad \text{대각행렬} \begin{pmatrix} 50 & 0 & 0 \\ 0 & 1 & 0 \\ 0 & 0 & 8 \end{pmatrix},$$

$$\text{단위행렬} \begin{pmatrix} 1 & 0 & 0 \\ 0 & 1 & 0 \\ 0 & 0 & 1 \end{pmatrix}, \quad \text{대칭행렬} \begin{pmatrix} 1 & 2 & 11 \\ 2 & 21 & 5 \\ 11 & 5 & 1 \end{pmatrix}$$



2.1.1 벡터와 행렬

■ 행렬 연산

■ **행렬 곱셈** $\mathbf{C} = \mathbf{AB}$, 이때 $c_{ij} = \sum_{k=1,s} a_{ik} b_{kj}$ (2.1)

2*3 행렬 $\mathbf{A} = \begin{pmatrix} 3 & 4 & 1 \\ 0 & 5 & 2 \end{pmatrix}$ 와 3*3 행렬 $\mathbf{B} = \begin{pmatrix} 2 & 0 & 1 \\ 1 & 0 & 5 \\ 4 & 5 & 1 \end{pmatrix}$ 을 곱하면 2*3 행렬 $\mathbf{C} = \mathbf{AB} = \begin{pmatrix} 14 & 5 & 24 \\ 13 & 10 & 27 \end{pmatrix}$

- 교환법칙 성립하지 않음: $\mathbf{AB} \neq \mathbf{BA}$
- 분배법칙과 결합법칙 성립: $\mathbf{A}(\mathbf{B} + \mathbf{C}) = \mathbf{AB} + \mathbf{AC}$ 이고 $\mathbf{A}(\mathbf{BC}) = (\mathbf{AB})\mathbf{C}$


■ 벡터의 내적

벡터의 내적 $\mathbf{a} \cdot \mathbf{b} = \mathbf{a}^T \mathbf{b} = \sum_{k=1,d} a_k b_k$ (2.2)

$\mathbf{x}_1 = \begin{pmatrix} 5.1 \\ 3.5 \\ 1.4 \\ 0.2 \end{pmatrix}$ 와 $\mathbf{x}_2 = \begin{pmatrix} 4.9 \\ 3.0 \\ 1.4 \\ 0.2 \end{pmatrix}$ 의 내적 $\mathbf{x}_1 \cdot \mathbf{x}_2$ 는 37.49

$\vec{v}_1 \cdot \vec{v}_2 = \begin{bmatrix} a & b \end{bmatrix} \begin{bmatrix} x \\ y \end{bmatrix} = ax + by$ why? \equiv

내적: 벡터에는 방향이 있으므로,
방향이 일치하는 만큼만 곱




2.1.1 벡터와 행렬

■ 텐서

- 3차원 이상의 구조를 가진 숫자 배열
- 예) 3차원 구조의 RGB 컬러 영상

$$A = \begin{pmatrix} 4 & 1 & 0 & 3 & 2 & 2 \\ 2 & 0 & 2 & 2 & 3 & 1 & 6 \\ 3 & 0 & 1 & 2 & 6 & 7 & 6 & 3 \\ 3 & 1 & 2 & 3 & 5 & 6 & 3 & 0 \\ 1 & 2 & 2 & 2 & 2 & 3 & 0 & 3 \\ 3 & 0 & 0 & 1 & 1 & 0 & 3 & 1 \\ 5 & 4 & 1 & 3 & 3 & 3 & 1 & \\ 2 & 2 & 1 & 2 & 2 & 1 & & \end{pmatrix}$$



행렬은 2차원 숫자 배열을 표현할 수 있는데, 기계학습에서는 3차원 이상의 숫자 배열이 필요한 경우가 종종 있음 (RGB 영상 데이터 → 2차원 행렬이 세 장 있음)

스칼라: 0차원 텐서

벡터: 1차원 텐서

행렬: 2차원 텐서



2.1.2 놈과 유사도

Norm이 측정한 벡터의 크기는 원점에서 벡터 좌표까지의 거리 혹은 magnitude라고 함

■ 벡터와 행렬의 크기를 놈으로 측정

p=2일 때는 유클리드 공간에서의 일반적으로 이야기하는 거리에 해당한다.

- 벡터의 p 차 놈

$$p\text{차 놈: } \|\mathbf{x}\|_p = \left(\sum_{i=1,d} |x_i|^p \right)^{\frac{1}{p}} \quad (2.3)$$

$$\text{최대 놈: } \|\mathbf{x}\|_\infty = \max(|x_1|, |x_2|, \dots, |x_d|) \quad (2.4)$$

- 예) $\mathbf{x} = (3 \ -4 \ 1)$ 일 때, 2차 놈은 $\|\mathbf{x}\|_2 = (3^2 + (-4)^2 + 1^2)^{1/2} = 5.099$

- 행렬의 프로베니우스 놈

$$\text{프로베니우스 놈: } \|\mathbf{A}\|_F = \left(\sum_{i=1,n} \sum_{j=1,m} a_{ij}^2 \right)^{\frac{1}{2}} \quad (2.6)$$


$$\text{예를 들어, } \left\| \begin{pmatrix} 2 & 1 \\ 6 & 4 \end{pmatrix} \right\|_F = \sqrt{2^2 + 1^2 + 6^2 + 4^2} = 7.550$$




2.1.2 놀과 유사도

■ 유사도와 거리


- 벡터를 기하학적으로 해석



(a) 2차원 벡터



(b) 3차원 벡터



(c) 4차원 벡터(Iris 데이터)

그림 2-2 벡터를 기하학적으로 해석

두 벡터 사이의 거리 → 유클리디안 거리로 측정할 수 있고, 이는 벡터를 이용하여 2차 놀으로도 표현 가능함
→ 내적을 통해서 계산 가능


$$\mathbf{x} = (x_1, x_2), \mathbf{y} = (y_1, y_2) \rightarrow d(\mathbf{x}, \mathbf{y}) = \sqrt{(x_1 - y_1)^2 + (x_2 - y_2)^2} = \|\mathbf{x} - \mathbf{y}\|_2$$

$$\begin{aligned} d(\mathbf{x}, \mathbf{y}) &= \sqrt{x_1^2 + y_1^2 + x_2^2 + y_2^2 - 2(x_1 y_1 + x_2 y_2)} \\ &= \sqrt{\mathbf{x} \cdot \mathbf{x} + \mathbf{y} \cdot \mathbf{y} - 2\mathbf{x} \cdot \mathbf{y}} \end{aligned}$$

만약 벡터 \mathbf{x} 와 \mathbf{y} 가 같으면 0이 된다.



2.1.2 놈과 유사도



■ 유사도와 거리

■ 코사인 유사도

$$\text{cosine_similarity}(\mathbf{a}, \mathbf{b}) = \frac{\mathbf{a}}{\|\mathbf{a}\|} \cdot \frac{\mathbf{b}}{\|\mathbf{b}\|} = \cos(\theta) \quad (2.7)$$

유사도는 -1에서 1까지의 값을 가짐

: -1은 서로 완전히 반대되는 경우, 0은 서로 독립적인 경우, 1은 서로 완전히 같은 경우를 의미

주어진 두 벡터에
대해서 어떻게
cosine 값을 구할
것인가?


$$\mathbf{a} \cdot \mathbf{b} = \|\mathbf{a}\| \|\mathbf{b}\| \cos \theta$$

a, b가 직교하면,
 θ 가 90이 되고
 $\cos(90)$ 은 0이기
때문에 내적은 0이
된다.

1. 코사인 유사도(Cosine Similarity)

[참고] <https://wikidocs.net/24603>

코사인 유사도는 두 벡터 간의 코사인 각도를 이용하여 구할 수 있는 두 벡터의 유사도를 의미합니다. 두 벡터의 방향이 완전히 동일한 경우에는 1의 값을 가지며, 90°의 각을 이루면 0, 180°로 반대의 방향을 가지면 -1의 값을 갖게 됩니다. 즉, 결국 코사인 유사도는 -1 이상 1 이하의 값을 가지며 값이 1에 가까울수록 유사도가 높다고 판단할 수 있습니다. 이를 직관적으로 이해하면 두 벡터가 가리키는 방향이 얼마나 유사한가를 의미합니다.



코사인 유사도 : -1



코사인 유사도 : 0



코사인 유사도 : 1

두 벡터 A, B에 대해서 코사인 유사도는 식으로 표현하면 다음과 같습니다.

$$\text{similarity} = \cos(\theta) = \frac{\mathbf{A} \cdot \mathbf{B}}{\|\mathbf{A}\| \|\mathbf{B}\|} = \frac{\sum_{i=1}^n A_i \times B_i}{\sqrt{\sum_{i=1}^n (A_i)^2} \times \sqrt{\sum_{i=1}^n (B_i)^2}}$$



2.1.3 퍼셉트론의 해석

■ 퍼셉트론

- 1958년 로젠블랫이 고안한 분류기 모델




그림 2-3 퍼셉트론의 구조와 동작

- 퍼셉트론의 동작을 수식으로 표현하면,

$$o = \tau(\mathbf{w} \cdot \mathbf{x}), \quad \text{이때 } \tau(a) = \begin{cases} 1, & a \geq T \\ -1, & a < T \end{cases} \quad (2.8)$$

- 활성 함수 τ 로는 계단함수 사용

파란색 선: 두 개의 부분 공간을 나누는 결정 직선 (decision line)

벡터 \mathbf{w} 에 수직이고, 원점으로부터 $T/\|\mathbf{w}\|_2$ 만큼 떨어져 있고, 결정 직선에 위치한 점 \mathbf{x} 는 $\mathbf{w} \cdot \mathbf{x} = T$ 이다.


$\mathbf{w} \cdot \mathbf{x} < T$ 이면 -1, $\mathbf{w} \cdot \mathbf{x} > T$ 이면 +1의 공간으로 나누는 것




2.1.3 퍼셉트론의 해석

■ 퍼셉트론

- [그림 2-3(c)]의 파란 직선은 두 개의 부분공간을 나누는 결정직선decision line
 - \mathbf{w} 에 수직이고 $\frac{T}{\|\mathbf{w}\|_2}$ 만큼 떨어져 있음
- 3차원 특징공간은 결정평면decision plane, 4차원 이상은 결정 초평면decision hyperplane
- 예) 3차원 특징공간을 위한 퍼셉트론



(a) 퍼셉트론



(b) 공간 분할(2부류 분류)

그림 2-4 퍼셉트론의 예(3차원)



2.1.3 퍼셉트론의 해석

■ 출력이 여러 개인 퍼셉트론




그림 2-5 출력이 여러 개인 퍼셉트론

출력은 벡터 $\mathbf{o} = (o_1, o_2, \dots, o_c)^T$ 로 표기

j 번째 퍼셉트론의 가중치 벡터를

$\mathbf{w}_j = (w_{j1}, w_{j2}, \dots, w_{jd})^T$ 와 같이 표기

- 동작을 수식으로 표현하면,

$$\mathbf{o} = \tau \begin{pmatrix} \mathbf{w}_1 \cdot \mathbf{x} \\ \mathbf{w}_2 \cdot \mathbf{x} \\ \vdots \\ \mathbf{w}_c \cdot \mathbf{x} \end{pmatrix}$$



행렬로 간결하게 쓰면 $\mathbf{o} = \tau(\mathbf{W}\mathbf{x})$

이때 $\mathbf{W} = \begin{pmatrix} \mathbf{w}_1^T \\ \mathbf{w}_2^T \\ \vdots \\ \mathbf{w}_c^T \end{pmatrix}$

- 가중치 벡터를 각 부류의 기준 벡터로 간주하면, c 개 부류의 유사도를 계산하는 셈



2.1.3 퍼셉트론의 해석

■ 학습의 정의

- 식 (2.10)은 학습을 마친 프로그램을 현장에 설치했을 때 일어나는 과정

분류라는 과정: $\overset{?}{\tilde{\mathbf{o}}} = \tau(\overset{\text{앞}}{\tilde{\mathbf{W}}} \overset{\text{앞}}{\tilde{\mathbf{x}}})$ (2.10)

- 식 (2.11)은 학습 과정

- 학습은 훈련집합의 샘플에 대해 식 (2.11)을 가장 잘 만족하는 \mathbf{w} 를 찾아내는 작업

학습이라는 과정: $\overset{\text{앞}}{\tilde{\mathbf{o}}} = \tau(\overset{?}{\tilde{\mathbf{W}}} \overset{\text{앞}}{\tilde{\mathbf{x}}})$ (2.11)

■ 현대 기계 학습에서 퍼셉트론의 중요성

- 딥러닝은 퍼셉트론을 여러 층으로 확장하여 만듦



2.1.4 선형결합과 벡터공간

■ 벡터

- 공간상의 한 점으로 화살표 끝이 벡터의 좌표에 해당

■ 선형결합이 만드는 벡터공간

- 기저벡터 **a**와 **b**의 선형결합

$$\mathbf{c} = \alpha_1 \mathbf{a} + \alpha_2 \mathbf{b}$$

- 선형결합으로 만들어지는 공간을 **벡터공간**이라 부름


벡터 **a**와 **b**에 각각 상수를 곱한 다음 결과를 더하는 연산을 선형결합(linear combination)이라고 한다.

→ 퍼셉트론에서 $\mathbf{w} \cdot \mathbf{x}$ 에 해당한다.

그림 2-7에서 α_1 와 α_2 를 변형시키면 2차원 공간의 모든 점을 만들 수 있다. 즉 **a**와 **b**의 선형결합으로 2차원 공간 전체를 덮을 수 있다.


2-6에서는 α_1 와 α_2 를 변형시켜도 결코 직선을 벗어나지 못한다. 이런 경우(즉, 기저벡터가 선형독립이 아닌 경우) 벡터 공간을 만들 수 없다.

기계 학습에서는 행렬의 공간 변환 능력을 이용하여 분류모델을 만든다. 딥러닝은 공간 변환을 잘하기 때문에 성능이 높은 것이고, 벡터공간이 만들어지지 않는다면 학습이 잘 안될 수 있다.




(a) 벡터에 스칼라 곱

그림 2-6 벡터의 연산




(b) 두 벡터의 덧셈



(a) 기저 벡터와 벡터공간

그림 2-7 벡터공간




(b) 정규직교 기저 벡터




2.1.5 역행렬

■ 역행렬의 원리



(a) 역수의 원리



(b) 역행렬의 원리

그림 2-9 역행렬

- 정사각행렬 A 의 역행렬 A^{-1} (모든 행렬이 역행렬을 갖는 것은 아니다)

$$A^{-1}A = AA^{-1} = I$$

- 예를 들어,

$$\begin{pmatrix} 2 & 1 \\ 6 & 4 \end{pmatrix} \text{의 역행렬은 } \begin{pmatrix} 2 & -0.5 \\ -3 & 1 \end{pmatrix}$$

예를 들어 2에 3을 곱하면 6으로 변환됨.

변환된 6을 원래 값으로 역변환 하려면 3의 역수 즉 $3^{-1}=1/3$ 을 곱하면 됨.

데이터 분석 과정에서 역행렬은 많이 활용됨 (뒤 고유값 분해)



2.1.5 역행렬



■ 행렬 \mathbf{A} 의 행렬식 $\det(\mathbf{A})$

$$\left. \begin{aligned} \det \begin{pmatrix} a & b \\ c & d \end{pmatrix} &= ad - bc \\ \det \begin{pmatrix} a & b & c \\ d & e & f \\ g & h & i \end{pmatrix} &= aei + bfg + cdh - ceg - bdi - afh \end{aligned} \right\} \quad (2.15)$$

예를 들어 $\begin{pmatrix} 2 & 1 \\ 6 & 4 \end{pmatrix}$ 의 행렬식은 $2*4-1*6=2$

■ 기하학적 의미

- 2차원에서는 2개의 행 벡터가 이루는 평행사변형의 넓이
- 3차원에서는 3개의 행 벡터가 이루는 평행사각기둥의 부피



행렬식이 0이라는 것은 행렬을 구성하는 벡터가 서로 동일선상(collinear)에 있다는 것을 의미함

이는 행렬을 구성하는 벡터가 해당 공간의 기저가 아님을 의미한다.

그림 2-10 행렬식의 기하학적 해석



2.1.6 행렬 분해

■ 분해란?

- 정수 3717은 특성이 보이지 않지만, $3 \times 3 \times 7 \times 59$ 로 소인수 분해를 하면 특성이 보이듯이, 행렬도 분해하면 여러모로 유용함

■ 고유값과 고유 벡터

- 고유 벡터 \mathbf{v} 와 고유값 λ

$$A\mathbf{v} = \lambda\mathbf{v}$$

- 예를 들어, $\begin{pmatrix} 2 & 1 \\ 1 & 2 \end{pmatrix} \begin{pmatrix} 1 \\ 1 \end{pmatrix} = 3 \begin{pmatrix} 1 \\ 1 \end{pmatrix}$ 이고 $\begin{pmatrix} 2 & 1 \\ 1 & 2 \end{pmatrix} \begin{pmatrix} 1 \\ -1 \end{pmatrix} = 1 \begin{pmatrix} 1 \\ -1 \end{pmatrix}$ 이므로,

$$\lambda_1 = 3, \lambda_2 = 1 \text{이고}$$

$$\mathbf{v}_1 = \begin{pmatrix} 1 \\ 1 \end{pmatrix}, \mathbf{v}_2 = \begin{pmatrix} 1 \\ -1 \end{pmatrix}$$

$w \cdot x$

$$c = \alpha_1 a + \alpha_2 b$$

x 에 해당하는 것이 (a, b)

(물론 x 는 행렬, a, b 는 벡터)

x 에 α 에 해당하는 w 를 선형결합하면
벡터공간 만들어짐

$$\rightarrow A\mathbf{x} = \lambda\mathbf{x}$$

$\rightarrow \lambda$ 는 원본 벡터 x 를 A 로 선형변환 했을 때
얼마나 축소하고 확대했는지에 대한 값



2.1.6 행렬 분해

■ 고윳값과 고유 벡터의 기하학적 해석

예제 2-5

[그림 2-12]의 반지름이 1인 원 위에 있는 4개의 벡터 $\mathbf{x}_1, \mathbf{x}_2, \mathbf{x}_3, \mathbf{x}_4$ 가 $\mathbf{A} = \begin{pmatrix} 2 & 1 \\ 1 & 2 \end{pmatrix}$ 에 의해 어떻게 변환되는지 살펴보자. 변환 후의 벡터를 각각 $\mathbf{x}'_1, \mathbf{x}'_2, \mathbf{x}'_3, \mathbf{x}'_4$ 로 표기한다.

$$\mathbf{x}'_1 = \begin{pmatrix} 2 & 1 \\ 1 & 2 \end{pmatrix} \begin{pmatrix} 1/\sqrt{2} \\ 1/\sqrt{2} \end{pmatrix} = \begin{pmatrix} 3/\sqrt{2} \\ 3/\sqrt{2} \end{pmatrix}$$

$$\mathbf{x}'_2 = \begin{pmatrix} 2 & 1 \\ 1 & 2 \end{pmatrix} \begin{pmatrix} 1 \\ 0 \end{pmatrix} = \begin{pmatrix} 2 \\ 1 \end{pmatrix}$$

$$\mathbf{x}'_3 = \begin{pmatrix} 2 & 1 \\ 1 & 2 \end{pmatrix} \begin{pmatrix} 1/\sqrt{2} \\ -1/\sqrt{2} \end{pmatrix} = \begin{pmatrix} 1/\sqrt{2} \\ -1/\sqrt{2} \end{pmatrix}$$

$$\mathbf{x}'_4 = \begin{pmatrix} 2 & 1 \\ 1 & 2 \end{pmatrix} \begin{pmatrix} 0 \\ -1 \end{pmatrix} = \begin{pmatrix} -1 \\ -2 \end{pmatrix}$$

눈 여겨 볼 점은 \mathbf{A} 의 고유 벡터 $\begin{pmatrix} 1 \\ 1 \end{pmatrix}, \begin{pmatrix} 1 \\ -1 \end{pmatrix}$ 과 방향이 같은 \mathbf{x}_1 과 \mathbf{x}_3 이다. 이들은 변환 때문에 길이가 달라지더라도 방향은 그대로 유지한다. 식 (2.20)을 충실히 따르고 있다. 이때 길이의 변화는 고윳값 λ 에 따른다. 즉, \mathbf{x}_1 은 3배 만큼, \mathbf{x}_3 은 1배만큼 길이가 변한다. 나머지 \mathbf{x}_2 와 \mathbf{x}_4 는 길이와 방향이 모두 변한다. 파란 원 위에 있는 모든 점을 변환하면 빨간색의 타원이 된다. 파란 원 위에 존재하는 무수히 많은 점(벡터) 중에 방향이 바뀌지 않는 것은 고유 벡터에 해당하는 \mathbf{x}_1 과 \mathbf{x}_3 뿐이다.




그림 2-12 고유 벡터의 공간 변환

▪ 예를 들어, $\begin{pmatrix} 2 & 1 \\ 1 & 2 \end{pmatrix} \begin{pmatrix} 1 \\ 1 \end{pmatrix} = 3 \begin{pmatrix} 1 \\ 1 \end{pmatrix}$ 이고 $\begin{pmatrix} 2 & 1 \\ 1 & 2 \end{pmatrix} \begin{pmatrix} 1 \\ -1 \end{pmatrix} = 1 \begin{pmatrix} 1 \\ -1 \end{pmatrix}$ 이므로,

$\lambda_1 = 3, \lambda_2 = 1$ 이고

$$\mathbf{v}_1 = \begin{pmatrix} 1 \\ 1 \end{pmatrix}, \mathbf{v}_2 = \begin{pmatrix} 1 \\ -1 \end{pmatrix}$$



2.1.6 행렬 분해

■ 고윳값 분해 eigen value decomposition

$$A = Q\Lambda Q^{-1} \quad (2.21)$$

- Q 는 A 의 고유 벡터를 열에 배치한 행렬이고 Λ (람다의 대문자)는 고윳값을 대각선에 배치한 대각 행렬
- 예를 들어, $\begin{pmatrix} 2 & 1 \\ 1 & 2 \end{pmatrix} = \begin{pmatrix} \boxed{1} & \boxed{1} \\ 1 & -1 \end{pmatrix} \begin{pmatrix} 3 & 0 \\ 0 & 1 \end{pmatrix} \begin{pmatrix} 0.5 & 0.5 \\ 0.5 & -0.5 \end{pmatrix}$
- 고윳값 분해는 정사각행렬에만 적용 가능한데, 기계 학습에서는 정사각행렬이 아닌 경우의 분해도 필요하므로 고윳값 분해는 한계를 가짐



고유값 분해 eigen value decomposition

고유값 분해(eigen decomposition)

정방 행렬($n \times n$) A 를 선형 변환으로 봤을 때(즉 열벡터 v 에 행렬 A 를 곱하는 것), 선형 변환 A 에 의한 변환 결과가 자기 자신(열벡터 v)의 상수 배가 되는 0이 아닌 벡터를 고유벡터(eigenvector, v)라고 하고, 이 상수배 값을 고유값(eigenvalue, λ)이라고 함

$$\rightarrow Av = \lambda v$$

$Av = \lambda v$ 이 만족한다는 것은 벡터 v 에 대해 선형 변환 A 를 해주었을 때, 벡터 v 의 방향은 변하지 않고 크기만 변했다는 뜻

보통 어떤 벡터에 선형 변환을 하면 방향이 바뀐다. 하지만 선형 변환을 했음에도 어떤 벡터 v 의 방향이 바뀌지 않고 크기만 변했다면, 그리고 변한 크기가 원래 벡터 크기의 λ 배라면 그 λ 를 고유값이라고 하고 v 는 고유 벡터라고 함

행렬 A 의 고유 벡터들을 열 벡터로 하는 행렬을 Q (v 에서 도출), 고유값을 대각원소로 가지는 대각 행렬을 Λ 라 하면 다음 식이 성립

$$\rightarrow AQ = Q\Lambda$$

$$\rightarrow A = Q\Lambda Q^{-1}$$

이것을 행렬 A 에 대한 고유값 분해라고 함

$$A \begin{bmatrix} v_1 & v_2 & \cdots & v_n \end{bmatrix} = \begin{bmatrix} \lambda_1 v_1 & \lambda_2 v_2 & \cdots & \lambda_n v_n \end{bmatrix}$$
$$= \begin{bmatrix} v_1 & v_2 & \cdots & v_n \end{bmatrix} \begin{bmatrix} \lambda_1 & & & 0 \\ & \lambda_2 & & \\ & & \ddots & \\ 0 & & & \lambda_n \end{bmatrix}$$

$$\begin{pmatrix} v_{11} & v_{12} & v_{13} \\ v_{21} & v_{22} & v_{23} \\ v_{31} & v_{32} & v_{33} \end{pmatrix} \begin{pmatrix} \lambda_1 & 0 & 0 \\ 0 & \lambda_2 & 0 \\ 0 & 0 & \lambda_3 \end{pmatrix} = \begin{pmatrix} \lambda_1 v_{11} & \lambda_2 v_{12} & \lambda_3 v_{13} \\ \lambda_1 v_{21} & \lambda_2 v_{22} & \lambda_3 v_{23} \\ \lambda_1 v_{31} & \lambda_2 v_{32} & \lambda_3 v_{33} \end{pmatrix}$$

대각행렬은 위 그림과 같이 대각 원소의 크기 만큼 상수배가 될 수 있음



2.1.6 행렬 분해

$A = Q\Lambda Q^{-1} \rightarrow$ 정방행렬 $n \times n$ 에만 가능

■ $m \times n$ 행렬 A 의 특이값 분해 SVD(singular value decomposition)

$$A = U\Sigma V^T \quad (2.22)$$

- 왼쪽 특이행렬 U 는 AA^T 의 고유 벡터를 열에 배치한 $m \times m$ 행렬
- 오른쪽 특이행렬 V 는 $A^T A$ 의 고유 벡터를 열에 배치한 $n \times n$ 행렬
- Σ 는 AA^T 의 고유값의 제곱근을 대각선에 배치한 $m \times n$ 대각행렬

예를 들어, A 를 4×3 행렬이라고 했을 때 다음과 같이 특이값 분해가 된다.

$$A = \begin{pmatrix} 1 & 0 & 0 \\ 0 & 2 & 2 \\ 3 & 1 & 0 \\ 1 & 0 & 2 \end{pmatrix} = \begin{pmatrix} -0.1914 & -0.2412 & 0.1195 & -0.9439 \\ -0.5144 & 0.6990 & -0.4781 & -0.1348 \\ -0.6946 & -0.6226 & -0.2390 & 0.2697 \\ -0.4651 & 0.2560 & 0.8367 & 0.1348 \end{pmatrix}$$
$$\begin{pmatrix} 3.7837 & 0 & 0 \\ 0 & 2.7719 & 0 \\ 0 & 0 & 1.4142 \\ 0 & 0 & 0 \end{pmatrix} \begin{pmatrix} -0.7242 & -0.4555 & -0.5177 \\ -0.6685 & 0.2797 & 0.6891 \\ 0.1690 & -0.8452 & 0.5071 \end{pmatrix}$$

$$\begin{aligned} A &= U \Sigma V^T \\ \therefore AA^T &= U \Sigma V^T (U \Sigma V^T)^T \\ &= U \Sigma V^T V \Sigma^T U^T \\ &= U \Sigma \Sigma^T U^T \\ &= U (\Sigma \Sigma^T) U^{-1} \quad \{ \because U^T = U^{-1} \text{ 이므로 } \} \\ \therefore AA^T \text{를 고유값 분해 하면} \\ &U (\Sigma \Sigma^T) U^{-1} \text{가 됨.} \\ \Rightarrow U \text{는 } AA^T \text{의 고유벡터들로 구성된 행렬} \end{aligned}$$



특이값 분해의 활용




그림. 특이값 분해를 통해 얻어진 U , Σ , V 행렬에서 일부만을 이용해 적당한 A' 를 부분복원 하는 과정

특이값 분해는 분해되는 과정보다는 분해된 행렬을 다시 조합하는 과정이 더 많이 응용이 됨

기존의 U, Σ, V^T 로 분해되어 있던 A 행렬을 특이값 p 개만을 이용해 A' 라는 행렬로 '부분 복원' 시킬 수 있다. (A' 는 A 와 완전히 같지는 않지만 거의 근사하다)

특이값의 크기에 따라 A 의 정보량이 결정되기 때문에 값이 큰 몇 개의 특이값들을 가지고도 충분히 유용한 정보를 유지할 수 있다.

